

Алгоритмы. Теор.листок 2

Артемий Клячин

26 октября 2021 г.

Задача 1.

Построим общее сжатое суффиксное дерево *sufftree* для строк S, S^{-1} за $O(n)$.

$LCP(S, T)$ - наибольшая общий префикс строк S и T .

$LCA(S, T)$ - наименьший общий предок вершин соответствующих строкам S и T .

Пусть $LCE(S, T, i, j) = LCP(S[i:], P[j:])$

$LCE(S, T, i, j)$ определяется меткой LCA на *sufftree* для $S[i:]$ и $T[j:]$. Т.е. для листов суффиксов $S[i:]$ и $T[j:]$ надо найти ближайшего общего предка, а по глубине предка узнает длину наибольшего общего префикса.

Есть способ находить LCA за $O(1)$ с препроцессингом за $O(N)$ (алгоритм Фарах-Колтона и Бендера). Таким образом мы можем делать LCE за $O(1)$.

$LCE(S, S^{-1}, i, (n-1)-i)$ - это длина наибольшего палиндрома нечётной длины с центром в i .

$LCE(S, S^{-1}, i+1, (n-1)-i)$ - это длина наибольшего палиндрома чётной длины с центром в i и $i+1$.

Таким образом за $O(n)$ мы получим ответ на задачу.

Итоговая асимптотика $O(n)$.

Задача 2.

Введём понятия:

Строка y *сильно* продолжает строку x , если после каждого вхождения x в y следует вхождение y .

Строка y *очень слабо* продолжает строку x , если y слабо и несильно продолжает строку x .

Построим сжатое суффиксное дерево.

Возьмём произвольный x - ему соответствует какая-то позиция на каком-то ребре.

Количество сильных продолжений - это расстояние в символах до ближайшей вершины дерева. (далее будет разветвление и сильного продолжения не существует)

Далее посчитает очень слабые продолжения. Если мы подсчитаем их для вершины v , то их количество будет таким же для всех позиций на ребре (p, v) (кроме самой вершины p), где p - вершина-предок вершины v .

Так как любые два очень слабых продолжения x либо совпадают, либо один является префиксом другого, то очень слабые продолжения находятся на одном пути в некоторый лист u .

Другие продолжения не могут быть такой же длины, что и очень слабое продолжение, следовательно, посимвольная глубина позиции, в которую попадает очень слабое продолжение должна быть больше, чем у любого другого продолжения не на пути к u .

Любое подобное продолжение на пути к u будет очень слабым.

Следовательно, количество очень слабых продолжений x будет $h_1 - h_2$, где h_1 и h_2 - длины двух самых глубоких невложенных продолжения ($h_1 \geq h_2$).

Алгоритм:

за $O(N)$ строим дерево, за $O(N)$ при помощи DFS ищем 2 самых больших продолжения для каждой вершины, за $O(N)$ обходим все ребра и для каждого x , за $O(1)$ вычисляем количество слабых (сильных и очень слабых) продолжений.

e - ребро сжатого суффиксного дерева.

$len(e)$ - количество x на ребре e .

v_e - более глубокая вершина e

Ответ: $\sum_e \frac{len(e) \cdot (len(e)-1)}{2} + m \cdot (h_1(v_e) - h_2(v_e))$

Задача 3.

Построить суффиксное дерево $s_1\$1s_1\$2...s_ns_n\$n$, где $\$1, ..., \n - разные окончания.

Далее каждой строкой пройдем по дереву. Если для строки s_i есть продолжение отличное от $\$i$, то для s_i ответ YES, иначе NO.

Оценка асимптотики:

1) Построение дерева - $O(\sum_{i=1}^n |s_i|)$

2) Проход всех строк по дереву происходит суммарно за $O(\sum_{i=1}^n |s_i|)$.

Итоговая асимптотика: $O(\sum_{i=1}^n |s_i|)$

Задача 4.

Построим общее сжатое суффиксное дерево для $s_1, s_1, ..., s_n$. В каждой вершине дерева будем хранить список строк, для которых данная вершина является терминальной. Такие списки будем называть списками терминальных состояний.

Далее каждой строкой s_i пройдёмся по дереву и обработаем для каждой вершины списки терминальных состояний. Если для строки s_j , вершина, в которую мы попали - терминальная, то существует суффикс s_j , который является префиксом s_i . И наоборот, если p строка является префиксом s_i и суффиксом s_j , то она обязательно попадётся при обходе. Так как нас интересуют максимальные такие p , то будем искать последнее вхождение строки s_j в списки терминальных состояний.

По итогу мы получили по $n - 1$ значений для каждой строки s_i . Которые и будут ответом на задачу.

Оценка асимптотики:

1) Построение дерева - $O(n)$

2) Пусть $m = \sum_{i=1}^n |s_i|$.

Для каждой строки производим спуск вниз по дереву и обрабатываем терминальные списки. Спуск производится за $O(m)$. Для каждой строки s_i , количество терминальных вершин $|s_i|$, следовательно, длины всех терминальных списков m , поэтому суммарно для всех $s[i]$ их обработка займёт $O(m)$.

3) По итогу алгоритма имеется n списков по $n - 1$ значению. Ответ выводим за $O(n^2)$

Итоговая асимптотика: $O(\sum_{i=1}^n |s_i| + n^2)$

Задача 5.

Количество различных подстрок в строке - это сумма длин всех рёбер в сжатом суффиксном дереве +1 (пустое подслово).

Решим задачу с помощью алгоритма Укконена. Алгоритм Укконена постепенно строит дерево: в начале строит дерево для $s[0, 0]$, потом $s[0, 1]$, ... $s[0, n - 1]$. Дополнительно, на каждой итерации, считаем сумму длин рёбер суфф.дерева для $s[0, i]$, используя результат для предыдущей итерации: $i - 1$

Так как асимптотика Укконена $O(|s|)$, то асимптотика алгоритма $O(|s|)$.